Onde estocar o item reparável?

METRIC e VARI-METRIC, da intuição à formulação

Prof. Celio Mesquita

TE-292 — Ciência de Dados em Operação e Manutenção de Aeronaves
Aula 4

Esta versão constrói cada equação depois de a intuição estar de pé. A ordem é deliberada: primeiro a pergunta operacional, depois a conta. Fonte completa: `../LaTeX/metric_pt.pdf`. Código: `../metric.py`. Dados: `parts2B12P.toml` e `parts5B25P.toml`.

Uma aeronave em AOG

Quanto tempo ela fica no solo?

A resposta certa é **depende**.

A aula inteira é sobre *de quê* depende.

Abrir pela pergunta operacional; o modelo entra depois. Deixar a turma listar do que depende: disponibilidade do item, tempo de reparo, transporte, prioridade. Todos esses aparecem como parâmetro nomeado nos próximos slides — vale voltar a esta lista quando aparecerem.

Depende de uma coisa só

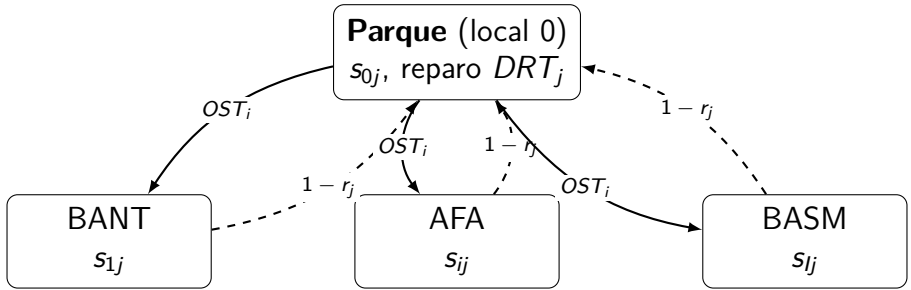
O LRU falhou. Havia um reparável **estocado**?

Se havia: troca hoje.

Se faltava: espera o ciclo inteiro.

Toda a matemática existe para responder duas perguntas: quantos estocar e onde. Estocar imobiliza capital; a falta imobiliza aeronave. O modelo é o instrumento para arbitrar esse par.

O sistema: dois escalões



Cada base é servida só pelo parque. Sistema conservativo.

Símbolos. $i = 1, \ldots, I$: bases; $j = 1, \ldots, N$: itens reparáveis; local 0: o parque. s_{0j}, s_{ij}: estoque *autorizado* do item j (unidades). DRT_j: tempo médio de reparo no parque (dias). OST_i: pedido e embarque parque→base (dias). r_j: fração reparada na base.

Seta cheia: reparável descendo. Tracejada: falhado subindo. Duas hipóteses a marcar já: cada base é servida só pelo parque, e o item volta reparado ao acervo. São as primeiras que a realidade viola.

A política $(s-1, s)$

Cada falha dispara **uma** reposição, imediatamente.

A posição de estoque retorna sempre a s.

Caso-limite $Q = 1$ de uma política (s, S).

Símbolos. s: nível-alvo autorizado; $s-1$: ponto de ressuprimento; Q: quantidade de pedido.

Justifica-se quando a economia de agrupar pedidos é desprezível diante do custo de imobilizar unidades adicionais — típico de rotáveis e aviônica. Para item barato de alto giro o modelo é outro (EOQ). Consequência técnica importante: como a posição volta a s após cada demanda, o sistema fica descrito por uma *única* variável aleatória, que é o assunto da próxima seção.

Os dados: por base

OST_i	pedido e embarque (d)
$assets_i$	aeronaves sediadas
$duty_cycle_i$	fração do calendário em operação

$duty_cycle_i = 0{,}15$ é 3,6 h de voo por dia.

Armadilha recorrente: *duty_cycle* mede a fração do calendário em que *cada* aeronave opera. O modelo já multiplica por $assets_i$; usar parcela da frota aqui conta a base duas vezes. É o erro mais comum quando o aluno monta o próprio dataset.

Os dados: por item

$cost_j$	custo unitário (USD)
λ_j	falhas por hora de *operação*
qpa_j	unidades por aeronave
DRT_j, BRT_j	reparo no parque, na base (d)
r_j	fração reparada na base

Só **médias** de tempo — e é só disso que o modelo precisa.

É consequência do teorema de Palm, que aparece daqui a seis slides e é testado empiricamente no fim da aula. Anunciar agora e cobrar depois.

O caso numérico da aula

Atuador de flap: **\$ 10.000**, uma falha a cada **10 dias** por base.

Parque: **20 d**. Transporte: **2 d**. Reparo na base: **3 d**.

3 bases, e **3 em cada 10** falhas a base resolve.

Escrever no quadro e deixar visível a aula inteira: $DR_{ij} = 0{,}1$/dia, $DRT_j = 20$ d, $OST_i = 2$ d, $BRT_j = 3$ d, $r_j = 0{,}3$, $I = 3$. Todos os números dos próximos slides saem daqui. É um caso didático — o dataset real da disciplina é `parts2B12P.toml`, retomado no fim.

A decisão

Orçamento para **5** atuadores reserva.

Onde alocar cada um?

Nas bases? No parque? Em que proporção?

Votação de mão levantada, anotada no quadro: tudo nas bases, tudo no parque, ou dividido. Retomar no slide do acoplamento. A intuição majoritária — concentrar nas bases, perto do usuário — costuma ser a pior das três, e o motivo é o assunto central da aula.

O que contar

Pipeline: unidades devidas a um local neste instante.

Em reparo, em trânsito ou em pedido.

Símbolos. X: o pipeline, uma variável aleatória; X_{ij} na base i, X_{0j} no parque.

Sob $(s-1, s)$, esta é a única variável de estado estocástica necessária para descrever a situação de estoque do local. Se a turma sair da aula com um conceito só, que seja este.

A conta da prateleira

$$\text{prateleira} = \max(0,\ s - X)$$

$$\text{falta} \iff X > s$$

Acervo 3, pipeline 2 $\rightarrow$ **1** reparável.
Acervo 3, pipeline 5 $\rightarrow$ **2 aeronaves esperando**.

Distinção que rende discussão: *s* é *autorização* de posse, e a prateleira é o que sobra dela. Autorizado 3 e três em ressuprimento: prateleira vazia, taxa de atendimento zero, e o backorder ainda em *zero* — o backorder só nasce quando a próxima demanda chega. Backorder ocorre quando o pipeline *excede s*; a prateleira zera já quando o iguala.

Sua vez

A base tem $s_{ij} = \mathbf{2}$.

Hoje $X_{ij} = \mathbf{4}$.

Quantas aeronaves esperam?

Resposta: 2. Trinta segundos, resposta em voz alta. O erro típico é responder 4 — confundir pipeline com backorder. É o mesmo erro que aparece em relatório de gestão, então vale expor.

Taxa de demanda

$$DR_{ij} = \lambda_j \times duty_cycle_i \times assets_i \times qpa_j$$

$$DR_{0j} = \sum_{i=1}^{I} DR_{ij}\,(1 - r_j)$$

Símbolos. DR_{ij}: demanda da base i pelo item j, em falhas por hora de *calendário*; DR_{0j}: demanda que chega ao parque.

O *duty_cycle* converte a taxa de falha, cotada por hora de operação, para o relógio de calendário em que estão os lead times. Sem essa conversão, demanda e tempo ficam em relógios diferentes e todo o resto sai errado. É o erro de unidade mais comum quando o aluno monta o próprio dataset.

No caso da aula

$$DR_{ij} = \mathbf{0{,}1} \ /\text{dia}$$

$$DR_{0j} = 3 \times 0{,}1 \times 0{,}7 = \mathbf{0{,}21} \ /\text{dia}$$

Aqui $DR_{ij} = 0{,}1$ é dado direto, para manter o caso legível; num dataset real ele vem do produto do slide anterior. Confirmar com a turma o 0,21: três bases, cada uma a 0,1/dia, e só 70% chega ao parque.

Quantos mecânicos há na fila do suprimento?

Chegam **2 por minuto**.

Cada atendimento leva **5 minutos**.

Quantos há na fila, em média?

Deixar responder antes. Resposta: 10. A maioria acerta por intuição — e acabou de usar a Lei de Little antes de conhecer o nome. Aproveitar: a ferramenta central da aula é algo que eles já sabiam.

Lei de Little

$$\text{núm. méd. no sistema} = \text{taxa de chegada} \times \text{tempo méd. no sistema}$$

$$\text{pipeline médio} = \text{taxa de demanda} \times \text{tempo de ressuprimento}$$

Vale em qualquer sistema estável. Anunciar que ela aparece *três* vezes nesta aula: agora no pipeline, depois para converter backorders em tempo de espera, e por fim na construção do índice *Ao*. Reconhecer o padrão na terceira vez é mais valioso do que decorar as três fórmulas.

O pipeline do parque

$$\mu_{0j} = DR_{0j} \times DRT_j$$

$$0{,}21 \times 20 = \mathbf{4{,}20} \text{ atuadores}$$

Símbolos. μ_{0j}: média do pipeline do parque (unidades).

O parque se ressupre do próprio reparo: seu tempo de ressuprimento é DRT_j, e por isso a conta é direta. Média de 4,2 unidades permanentemente fora — o 0,2 existe como média, como "2,3 filhos por família".

Teorema de Palm

Demanda Poisson + tempos independentes + canais ilimitados

$\Rightarrow$ pipeline **Poisson** de média $DR \times T$.

Só a **média** de T importa. Qualquer forma de distribuição serve.

Símbolos. T: tempo médio de ressuprimento (h).

É a razão de os arquivos de entrada trazerem apenas médias. Enunciar a hipótese de canais ilimitados: toda unidade encontra bancada livre. Confortável para um parque com folga, frágil em oficina saturada. No fim da aula mostramos que a irrelevância da dispersão é *medida*, com o número ao lado.

O parque é exatamente Poisson

$$X_{0j} \sim \text{Poisson}(\mu_{0j}), \qquad VMR_{0j} = 1$$

Vale sob METRIC **e** sob VARI-METRIC.

Símbolos. *VMR*: razão variância/média do pipeline; vale 1 na Poisson.

Guardar: como o pipeline do parque já é exatamente Poisson, a variância está presa à média, e o segundo momento já fica determinado ali. Consequência — todo o cálculo do parque, inclusive δ_j, é idêntico nos dois métodos. Eles divergem *apenas* nas bases. Costuma surpreender.

O que a média esconde

Em média 1,63 atuadores no pipeline da base.

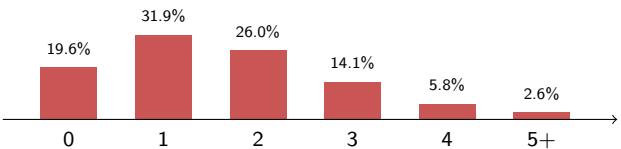
Em cada dia o valor realizado é **0, 1, 2, 3...**

Dimensionar exige a **distribuição inteira**.

Analogia rápida: a média do dado é 3,5, e o resultado sai sempre inteiro. Este slide justifica a distribuição do próximo. Se alguém perguntar de onde vem 1,63, responder que é o resultado da seção seguinte — está anunciado de propósito.

A distribuição do pipeline

$$P(k \mid \mu) = \frac{e^{-\mu}\mu^k}{k!}, \qquad k = 0, 1, 2, \ldots$$



Símbolos. $P(k \mid \mu)$: probabilidade de o pipeline valer k; k: contagem no pipeline.

Barras para $\mu = 1{,}63$. Perguntar: dia mais provável? (1 unidade, 32%). Chance de 3 ou mais? (cerca de 23%, quase um dia em quatro). No código a Poisson é avaliada em logaritmos, com $\log k! = \log \Gamma(k+1)$, para que k grande caiba na faixa de ponto flutuante.

Backorders esperados

$$EBO(s) = E\big[\max(X - s,\, 0)\big] = \sum_{k>s} (k - s)\, P(k)$$

Quantas unidades estão pendentes, em média.

Símbolos. $EBO(s)$: backorders esperados com estoque autorizado s (unidades).

Mesma função nos dois escalões: no código é literalmente a mesma chamada, `get_expected_backorders`, com os argumentos trocados. Uma função servir aos dois escalões é economia de implementação que vem da estrutura do modelo.

O que acontece ao estocar na base

s_{ij}	EBO_{ij}	ganho	FR_{ij}
0	1,630	—	0,0%
1	0,826	0,804	19,6%
2	0,341	0,485	51,5%
3	0,117	0,224	77,6%
4	0,034	0,083	91,7%

Duas leituras. O ganho marginal decresce a cada linha — é a convexidade discreta de que a análise marginal depende, aqui visível em números. E a taxa de atendimento fica em 19,6% com uma unidade e 51,5% com duas: para item de movimento lento e lead time longo, *FR* é péssimo guia de quanto comprar.

Taxa de atendimento imediato

$$FR_{ij}(s_{ij}) = P(X_{ij} < s_{ij}) = F_X(s_{ij} - 1)$$

É a CDF lida **um índice antes**.

Símbolos. $F_X(s) = P(X \leq s)$: função de distribuição acumulada do pipeline.

A prateleira atende uma demanda nova apenas se $s_{ij} - X_{ij} > 0$, o que é estritamente $P(X < s)$. No módulo, o parâmetro `min_fr` usa essa definição; corridas antigas que compararam $P(X \leq s)$ exigem recálculo antes do confronto. Diferença de um índice que muda o dimensionamento.

O número que engana

Com $s_{ij} = \mathbf{2}$:

$FR_{ij} = \mathbf{51{,}5\%}$ — parece inaceitável.

$EBO_{ij} = \mathbf{0{,}34}$ — é pouca aeronave parada.

As duas frases descrevem o mesmo estado. Uma meta de "95% de atendimento imediato"levaria a comprar 4 ou 5 unidades e gastar o triplo para remover 0,3 backorder. Escolher a métrica errada custa dinheiro real. É o slide que eu mais gostaria que sobrevivesse à aula.

De backorders a tempo de espera

Little, segunda aparição:

$$EBO_{0j} = DR_{0j}\, W_{0j} \qquad \Longrightarrow \qquad W_{0j} = \frac{EBO_{0j}}{DR_{0j}}$$

$$\frac{\text{unidades}}{\text{unidades/hora}} = \text{horas}$$

Símbolos. W_{0j}: espera média adicional, por demanda encaminhada ao parque, causada pela falta lá (horas).

Fazer a análise dimensional no quadro — é o que convence. W_{0j} é média sobre *todas* as demandas: as atendidas de imediato entram com espera zero, e ainda assim a média é alta, porque as que encontram falta esperam um reparo inteiro.

O fator de atraso

$$\delta_j(s_{0j}) = \frac{W_{0j}}{DRT_j} = \frac{EBO_{0j}(s_{0j})}{\mu_{0j}} = \frac{EBO_{0j}(s_{0j})}{EBO_{0j}(0)}$$

$\delta_j = 1$: parque zerado. $\delta_j = 0$: parque sempre atende.

Símbolos. δ_j: atraso do parque como fração de DRT_j; adimensional, entre 0 e 1.

Adimensionalizar é o truque que acopla os escalões preservando o conjunto de parâmetros. A última igualdade sai de $EBO_{0j}(0) = E[X] = \mu_{0j}$. Escrever no quadro: $\delta_j DRT_j$ é a espera média adicional causada pela falta no parque. É a ponte para a equação central.

δ_j no caso da aula

s_{0j}	EBO_{0j}	δ_j	RST_{ij}
0	4,200	1,000	16,3 d
1	3,215	0,765	13,0 d
2	2,293	0,546	**9,9 d**
3	1,503	0,358	7,3 d
4	0,899	0,214	5,3 d

Tabela calculada com $\mu_{0j} = 4{,}20$. A coluna RST_{ij} usa a equação do próximo slide — mostrar esta tabela antes dela é proposital: o aluno vê o efeito antes da fórmula. Duas unidades no parque cortam a espera da base de 16,3 para 9,9 dias.

A equação central

$$RST_{ij} = \underbrace{r_j BRT_j}_{\text{repara na base}} + \underbrace{(1 - r_j)\big(OST_i + \delta_j(s_{0j})\, DRT_j\big)}_{\text{depende do parque}}$$

$$\mu_{ij} = DR_{ij} \times RST_{ij}$$

Símbolos. RST_{ij}: tempo médio de ressuprimento visto pela base i (h); μ_{ij}: média do pipeline da base.

Aqui está a resposta à votação do início. Uma unidade no parque baixa δ_j e encolhe o pipeline de *todas* as bases do item, ao mesmo tempo. É por isso que o problema exige tratamento conjunto das bases — e é a diferença entre este modelo e dimensionar cada base isoladamente.

Estocar no parque

	$s_{0j} = 0$	$s_{0j} = 2$
δ_j	1,000	0,546
RST_{ij}	16,3 d	9,9 d
μ_{ij}	1,630	0,994

E isso **em cada uma** das três bases.

Retomar a votação. Duas unidades no parque tiram 6,4 dias da espera das três bases simultaneamente, mantendo as bases em zero. Quem votou "tudo nas bases"já tem o contra-exemplo.

Dois casos-limite

$\delta_j = 1$ (parque zerado):

$$RST_{ij} = r_j BRT_j + (1 - r_j)(OST_i + DRT_j)$$

$\delta_j = 0$ e $r_j = 0$:

$$RST_{ij} = OST_i$$

Checagem de sanidade coletiva: pedir que digam o resultado antes de mostrar. O primeiro é o *base stockage* de um escalão da RAND — todos esperam o reparo inteiro. O segundo é o ideal inalcançável: só o frete.

O objetivo

$$Z = \sum_{j=1}^{N} Z_j, \qquad Z_j = \sum_{i=1}^{I} EBO_{ij}(s_{ij}, s_{0j})$$

Backorders **das bases**. Os do parque entram por δ_j.

Símbolos. Z: objetivo do sistema; Z_j: parcela do item j.

Duas razões de Sherbrooke para preferir backorder à taxa de atendimento: maximizar *FR* empurra estoque para as bases, e aí toda demanda que encontra falta espera o pipeline completo; e backorders somam-se diretamente entre itens e bases, ao passo que taxas de atendimento só se combinam por média ponderada. O backorder do parque entra no objetivo indiretamente, por δ_j.

Análise marginal

$$\Delta Z_{j,\ell} = Z_j(\mathbf{s}_j^{(\ell+1)}) - Z_j(\mathbf{s}_j) \leq 0$$

$$g_{j,\ell} = |\Delta Z_{j,\ell}| \qquad BCR_{j,\ell} = \frac{|\Delta Z_{j,\ell}|}{cost_j}$$

Efetividade usa g. **Eficiência** usa BCR.

Símbolos. ℓ: um local, o parque ou uma base; $\mathbf{s}_j$: alocação corrente do item j; g: ganho marginal; BCR: razão benefício–custo.

No código é a chave `use_cost_weighting`. Vale rodar as duas em sala com o mesmo orçamento: com custos desiguais, efetividade compra o item caro que resolve muito, eficiência compra vários baratos. Cada uma é a certa num regime: eficiência quando o orçamento é restrição dura, efetividade quando a meta de disponibilidade manda.

Preços diferentes: um exemplo

	$g_{j,\ell}$	$cost_j$	$BCR_{j,\ell}$
Atuador	0,80	\$10.000	8×10^{-5}
Freio	0,20	\$1.000	2×10^{-4}

Maior ganho e melhor retorno por dólar são **itens diferentes**.

Deixar a turma decidir antes. O freio rende 2,5 vezes mais por dólar investido. Com orçamento apertado compra-se o freio primeiro; com meta de disponibilidade e orçamento folgado, o atuador. A escolha do critério de ranqueamento é decisão de engenharia, e cabe ao analista.

Por que o guloso funciona

Com o parque fixo:

$$g_{ij}(s_{ij}) = EBO(s_{ij}) - EBO(s_{ij}+1) = 1 - F_X(s_{ij}) = \Pr\{X_{ij} > s_{ij}\}$$

Permanece positivo e **decresce** a cada unidade $\Rightarrow$ convexidade discreta.

O ganho marginal é simplesmente a probabilidade de o pipeline exceder o estoque atual — conferir contra a coluna "ganho"da tabela de duas seções atrás. Com o parque fixo, o problema nas bases é separável e discretamente convexo, e escolher o maior ganho é exato para um número fixo de unidades.

O alcance da exatidão

Uma unidade no parque muda **todos** os pipelines do item, via δ_j.

Parque e bases formam **um problema acoplado**.

A sequência conjunta implementada é **heurística**.

Honestidade metodológica — e é o que a disciplina cobra nos trabalhos. Sherbrooke faz diferente: enumera o estoque de parque de cada item, resolve o subproblema convexo nas bases, convexifica a função de backorder e só então faz análise marginal entre itens. O `solve` atual substitui essa enumeração por uma varredura gulosa conjunta. O teste de orçamento também ocorre *depois* de acrescentar a unidade: o último ponto registrado está acima do teto.

O algoritmo

1. $s_{0j} \leftarrow 0$, $s_{ij} \leftarrow 0$, $C \leftarrow 0$.
2. Para cada item j e local ℓ, avaliar $\Delta Z_{j,\ell}$.
3. Alocar a unidade em $\arg\max$ do benefício.
4. Registrar $(C, Ao, \min FR)$.
5. Repetir até a regra de parada.

Símbolos. C: custo acumulado (USD); $\min FR$: menor taxa de atendimento entre todos os pares (item, base).

As regras de parada (`budget`, `min_fr`, `min_ao`, `all`) são acréscimo desta disciplina ao modelo original. A sequência (C, Ao) registrada é a curva de custo-efetividade que sai no fim da corrida — e é o artefato que o aluno entrega na tarefa.

A curva custo–desempenho



Onde parar é decisão de gestão: pesa o custo da indisponibilidade.

Mesma convexidade, agora como desenho. A parte íngreme é onde cada dólar rende muito; depois a curva deita. O ponto de parada depende do custo de indisponibilidade, que está fora do modelo — é decisão de quem administra a frota.

Do backorder à disponibilidade

Little, terceira aparição:

$$WT_i = \frac{\sum_j EBO_{ij}}{\sum_j DR_{ij}}, \qquad AWT_i = WT_i \times duty_cycle_i$$

$$MTBF_i = \frac{1}{\sum_j DR_{ij}}, \qquad Ao_i = \frac{MTBF_i}{MTBF_i + AWT_i}$$

Símbolos. WT_i: espera induzida por falta, por demanda (h); AWT_i: ajustada pelo ciclo de trabalho; $MTBF_i$: intervalo médio entre falhas da *frota* da base; Ao_i: índice da base.

Convenção *desta disciplina*, acrescentada ao METRIC de Sherbrooke — deixar explícito. O somatório agrega todos os itens da base, de modo que $\sum_j DR_{ij}$ é a taxa de demanda da frota inteira daquela base.

O índice do sistema

$$Ao = \frac{\sum_i assets_i \; duty_cycle_i \; Ao_i}{\sum_i assets_i \; duty_cycle_i}$$

Base grande e ocupada pesa mais.

Ponderação pelo programa de voo realizado. Uma base com 20 aeronaves voando muito deve pesar mais que um destacamento com duas aeronaves paradas.

O alcance de *Ao*

É **índice de planejamento**: serve para ranquear alocações.

Prever a disponibilidade de uma cauda ou da frota
exige **outro modelo**.

Por quê: a construção trata cada backorder aberto como uma aeronave parada, ignorando a chance de dois backorders atingirem a mesma cauda e qualquer correlação entre faltas. O fator *duty_cycle* em *AWT* conta só a fração da espera que seria operacional, tornando o índice menos pessimista. Serve para ordenar alternativas; prometer número a comandante exige outro modelo.

A ponta solta

Palm dá a **média** certa do pipeline da base.

A forma Poisson na base é **aproximação**.

O atraso do parque vem de uma prateleira **compartilhada** pelas três bases.

A hipótese que quebra é a independência dos tempos realizados: quando o parque zera, zera para as três bases ao mesmo tempo. O VARI-METRIC mantém a média e corrige a variância. Objetivo, análise marginal e *Ao* ficam intocados.

Partindo o pipeline da base

$$X_{ij} = \underbrace{P_{ij}}_{\text{reparo local ou trânsito}} + \underbrace{B_{0ij}}_{\text{esperando o parque}}$$

$$\mu_{ij}^{\text{fresh}} = DR_{ij}\big(r_j BRT_j + (1 - r_j) OST_i\big)$$

Símbolos. P_{ij}: parcela em reparo local ou em trânsito, Poisson; B_{0ij}: parcela da base i nos backorders do parque; μ_{ij}^{fresh}: média de P_{ij}.

Separar pelo *motivo* de a unidade estar em ressuprimento é a ideia toda. P_{ij} é privado da base i, e por isso Palm se aplica integralmente. B_{0ij} é onde as bases se encontram.

Os dois momentos

$$q_{ij} = \frac{DR_{0ij}}{DR_{0j}}, \qquad E[B_{0ij}] = q_{ij} E[B_{0j}]$$

$$\mathrm{Var}(B_{0ij}) = q_{ij}^2 \mathrm{Var}(B_{0j}) + q_{ij}(1 - q_{ij}) E[B_{0j}]$$

$$\mathrm{Var}(X_{ij}) = \mu_{ij}^{\text{fresh}} + \mathrm{Var}(B_{0ij}), \qquad VMR_{ij} = \frac{\mathrm{Var}(X_{ij})}{E[X_{ij}]}$$

Símbolos. q_{ij}: parcela da demanda de parque originada na base i, com $DR_{0ij} = (1 - r_j) DR_{ij}$; B_{0j}: backorders do parque.

Condicionado a $B_{0j} = b$, a base detém Binomial(b, q_{ij}) desses backorders; a lei da variância total dá os dois momentos com as hipóteses já assumidas. A *única* aproximação é tratar as duas parcelas de X_{ij} como independentes.

A média permanece

$$q_{ij} E[B_{0j}] = (1 - r_j) DR_{ij}\, \delta_j(s_{0j})\, DRT_j$$

Somando com μ_{ij}^{fresh} recupera-se

$$E[X_{ij}] = DR_{ij}\, RST_{ij}(s_{0j})$$

O VARI-METRIC muda **só a variância**.

É a pergunta que a turma faz. Consequência prática: rodar `metric.py` com `method="metric"` reproduz as respostas anteriores inalteradas, e qualquer diferença na tabela final vem exclusivamente da forma da distribuição da base.

Binomial negativa

$$\nu = \frac{\mu}{VMR - 1}, \qquad p = \frac{1}{VMR}$$

$$P(k) = \binom{k + \nu - 1}{k} p^{\nu} (1 - p)^{k}$$

Ajuste de **dois momentos** — daí o nome.

Símbolos. ν: parâmetro de tamanho; p: probabilidade de sucesso.

Armadilha de notação: ν é o parâmetro de tamanho da binomial negativa, distinto da fração de reparo r_j; e este p é a probabilidade de sucesso, distinta da parcela de demanda q_{ij}. *EBO* e *FR* mantêm as definições anteriores, só troca o $P(k)$. Quando $VMR \to 1$, a binomial negativa converge para a Poisson.

Quando a correção importa

$s_{0j} = 0$: tudo em backorder, $VMR = 1$ — VARI-METRIC **é** METRIC.

$s_{0j} \to \infty$: parque sempre atende, $VMR \to 1$ de novo.

Superdispersão máxima no **meio** — onde o otimizador trabalha.

É o argumento que justifica o esforço extra. Se a correção importasse só nos extremos, seria curiosidade teórica; ela é máxima exatamente na faixa que a otimização explora. Perguntar por que os dois extremos coincidem e deixar deduzirem.

Como saber se a conta está certa

Testa-se.

Simulação a eventos discretos, **livre** da aproximação de Palm.

Chegadas Poisson em cada base, prateleira de parque compartilhada, fila FCFS de backorders, canais amplos. Mede o *EBO* médio no tempo diretamente e compara com os dois modelos analíticos. Corridas de 8×10^5 demandas. Perguntar à turma como *eles* validariam antes de mostrar.

O resultado

	METRIC		VARI-METRIC	
Faixa	média	máx	média	máx
$EBO \geq 0{,}1$	6,58%	61,31%	0,76%	4,12%
$EBO \geq 0{,}01$	12,21%	86,90%	1,41%	17,34%
todos	17,16%	88,78%	3,51%	54,10%

Erro relativo de EBO_{ij} contra a simulação.

Três pontos. Onde há massa real de backorder, o erro médio cai 88%. O erro do METRIC é *unilateral* — subestima *EBO*, em até 87% —, a direção de viés que faz um modelo ainda por validar parecer tranquilizador. E na cauda extrema o VARI-METRIC também erra dezenas de por cento; alongar a corrida mantém esse erro, que é limite de casar dois momentos.

O mecanismo previsto é o observado

Em $s_{0j} = 7$, base BAFL:

previsto $VMR_{ij} = 1{,}472$ simulado **1,477**

Em $s_{0j} = 0$, ambos dão 1,000.

Além do erro agregado, melhora a quantidade que a construção de dois momentos prevê é a que a simulação mede. E em cinco bases desiguais, com parcelas de demanda de 0,55 a 0,009, o erro médio cai de 9,37% para 1,51% — a desagregação binomial se sustenta entre bases que diferem em duas ordens de grandeza.

O teorema de Palm, testado

Determinístico $\rightarrow$ lognormal de mesma média:

$CV = 0$	$VMR = 1{,}3250$
$CV = 0{,}8$	$VMR = 1{,}3247$
previsto	1,3249

O pipeline depende **só da média** do lead time.

Símbolos. CV: coeficiente de variação do lead time.

Fecha o círculo aberto no slide dos dados de entrada: os arquivos trazem só médias porque é só disso que o modelo precisa — e isso foi medido. É um bom exemplo de hipótese verificável sendo verificada.

As hipóteses que o modelo assume

Um único nível de indenture: a LRU repara direto.

Cada base depende **só** do parque.

Canais de reparo **ilimitados**.

Demanda Poisson de taxa conhecida.

Símbolos. LRU: *line replaceable unit*; SRU: *shop replaceable unit*.

O argumento de dois momentos se aplicaria de novo um nível de indenture abaixo, e exigiria a hierarquia LRU/SRU, que os datasets atuais ainda omitem. Perguntar quais dessas hipóteses quebram primeiro na operação que eles conhecem — as respostas costumam ser boas.

Da conta ao código

`parts2B12P.toml` — 2 bases, 12 itens, caso de ensino.

`parts5B25P.toml` — 5 bases, 25 itens, asas rotativas offshore.

`method`, `use_cost_weighting`, `budget`, `min_fr`, `min_ao`, `constraint_priority`

Duas armadilhas ao chamar `solve` diretamente: com `constraint_priority="min_fr"` o orçamento é ignorado, e uma meta inatingível compra até o teto de estoque; e se essa prioridade vier com `min_fr=0`, a meta é satisfeita de imediato e a corrida termina após uma unidade. Demonstração: `python metric.py`.

Síntese

1. O pipeline é a única variável de estado.
2. Palm: só as médias dos tempos importam.
3. δ_j acopla o parque a todas as bases.
4. O objetivo é backorder de base, porque é aditivo.
5. Os dois métodos diferem **só** no pipeline da base.
6. A métrica que se escolhe muda a decisão.
7. Validar contra simulação faz parte do método.

Amarrar com as três perguntas da disciplina: o modelo é adequado? mede o que afirma medir? é defensável para decidir? Os itens 5 e 7 respondem à segunda.